

PROFILE

실서비스 환경에서 LLM, RAG, AI Agent 시스템을 설계하고 성능·비용·안정성·데이터 보안 문제를 해결하는 실무 중심 AI Engineer입니다.

EXPERIENCE

GoyoAI AI Engineer

2023.12 — Present

외부 LLM 활용을 위한 PII 보안 계층 및 경량 탐지 모델

- 외부 LLM 호출 전 사용자 입력과 문서의 개인정보 및 민감정보를 검사하는 PII 보안 계층을 설계하고 실제 운영 환경에 적용
- 대용량 문서 입력 시 Qwen3 8B inference로 인한 처리 시간 증가 문제를 개선하기 위해 Qwen3 8B Teacher와 KLUE RoBERTa-large Student 간 Knowledge Distillation을 적용하여 경량 PII 탐지 모델을 프로토타입으로 구현
- Teacher와 Student의 탐지 결과를 비교하여 주요 테스트 시나리오에서 경량 모델의 탐지 성능을 검증하고, **평균 latency를 8.35초에서 0.06초로 단축하여 약 130배의 응답 속도 개선**

PII Detection Qwen3 8B Knowledge Distillation RoBERTa

Text2SQL 기반 정형 데이터 질의 시스템

- 기존 RAG 기반 질의 방식에서 유사도 검색만으로는 정형 데이터를 정확하게 조회하기 어려운 문제를 해결하기 위해 자연어 질문을 SQL로 변환하는 Text2SQL 구조를 적용
- SQL Example을 pgvector에서 검색하여 LLM의 SQL 생성을 보조하고, 자연어 질의를 SQL 생성으로 연결하는 Tool Calling 구조를 구성
- SQL 생성 및 조회 결과를 서비스에서 활용할 수 있도록 조회 결과와 전체 결과를 제공하는 API를 구현하고, 전체 조회 결과를 CSV로 저장할 수 있도록 구성

Text2SQL LLM Tool Calling PostgreSQL pgvector

역할 기반 AI Agent("인턴") 플랫폼 설계 및 개발

- 역할 기반 AI Agent 구축을 위해, Agent 이름·설명을 기반으로 시스템 프롬프트를 생성하고 참고 문서와 Tool을 설정할 수 있는 Builder를 구현
- 메일·일정·사내 공지·Notion·날씨·사내 투표 등의 기능을 LangChain 기반 Tool Calling으로 연동하여 Agent가 실제 업무를 수행할 수 있도록 구성
- RAG 문서 검색과 Perplexity 기반 웹 검색을 질의에 따라 분기하는 Hybrid 구조를 구현하고, 텍스트·참고 문서 기반의 답변 형식 커스터마이징 기능을 구현

LangChain Tool Calling RAG AI Agent

TECHNICAL SKILLS

AI / LLM LangChain · LangGraph · RAG · Text2SQL · PII Detection

Backend Python · FastAPI · Redis

Data PostgreSQL · pgvector · ChromaDB

EDUCATION

울산대학교

2018.03 — 2023.02

IT융합 · 소프트웨어공학

Naver Boostcamp AI Tech 4기

2022.09 — 2023.02

추천 시스템 · 머신러닝 엔지니어링

CERTIFICATE

ADsP

2024.06