

AI Engineer

LLM · RAG · AI Agent · Backend

PROFILE

실서비스 환경에서 **LLM · RAG · AI Agent**를 활용해 **AI 시스템을 개발하는 AI Engineer**입니다. B2B 환경에서 LLM 기반 PII Detection, Text2SQL, RAG 및 Tool Calling 기반 AI Agent를 설계하고 개발했습니다.

EXPERIENCE

GoyoAI AI Engineer

2023.12 — Present

외부 LLM 활용을 위한 PII 보안 계층 및 경량 탐지 모델

- 외부 LLM 호출 전 사용자 입력과 문서의 개인정보 및 민감정보를 탐지하는 **PII 보안 계층을 설계하고 운영 환경에 적용**. 탐지된 요청은 차단하거나, 관리자가 허용한 경우 PII를 마스킹한 후 외부 LLM을 호출하도록 구성
- Qwen3 8B를 Teacher 모델로 활용해 실제 OCR 문서와 LLM 기반 synthetic data를 바탕으로 학습 데이터를 구성하고, **KLUE RoBERTa-large Student 모델에 Knowledge Distillation을 적용** 하여 경량 PII 탐지 모델을 프로토타입으로 구현. OCR 특유의 개행 및 문자 변형을 포함한 **약 50개 테스트 케이스**로 Teacher/Student 모델의 탐지 결과를 비교 검증
- 평균 inference latency를 8.35초 → 0.06초로 단축하여 약 130배의 응답 속도 개선** 을 확인하고, 한자 낱자 표기·성별 오탐·주소 영역 확장 등 추가 개선이 필요한 케이스를 도출

PII Detection Qwen3 8B KLUE RoBERTa-large Knowledge Distillation

자연어 기반 정형 데이터 질의 및 Text2SQL 시스템

- 기존 ChromaDB 기반 RAG의 유사도 검색 방식에서 관련 데이터가 여러 건 존재하더라도 일부 Chunk만 검색되는 문제를 해결하기 위해, 자연어 질문을 SQL로 변환하여 **PostgreSQL에서 직접 조회하는 Text2SQL 시스템을 설계하고 운영 환경에 적용**
- pgvector에서 유사 질문-쿼리 예제 **64개를 검색**하고 BAAI/bge-reranker-v2-m3로 **상위 5개 Few-shot 예제를 선별**. 테이블 DDL·컬럼 설명·샘플 데이터 3행을 Schema Context로 제공하여 LLM이 데이터베이스 구조를 기반으로 SQL을 생성하도록 구성
- 생성된 SQL을 실행하고 오류 발생 시 **DB 오류 메시지를 LLM에 전달하여 SQL을 수정하고 재실행** 하는 흐름을 구현. 조회 결과는 Interactive Table로 제공하고 CSV 및 Excel Export를 지원

Text2SQL LLM Tool Calling PostgreSQL pgvector bge-reranker-v2-m3

역할 기반 AI Agent 구조 설계 및 개발

- 사용자 질문에 따라 필요한 기능과 정보를 Agent가 자율적으로 선택할 수 있도록 기존 RAG·Reranker와 사내 업무 서비스를 **Agent Tool로 구성**하고 LLM 기반 **Tool Calling 구조를 설계**. 문서 검색, 업무 데이터 조회 및 외부 정보 검색 등의 기능을 Tool로 구성하여 질문의 목적과 상황에 따라 적절한 Tool을 선택하고 실행하도록 구현
- 사용자 질문 → LLM의 Tool 선택 → 데이터 조회 → LLM 입력 데이터 구성 → 답변 생성** 의 실행 흐름을 구현. 문서 검색이 필요한 경우 RAG·Reranker를 활용하고, 업무 데이터가 필요한 경우 백엔드 API를 호출하여 조회된 데이터를 LLM이 처리하기 적합한 형태로 구성한 후 최종 답변을 생성하도록 구현

LangChain Tool Calling RAG Reranker

TECHNICAL SKILLS

AI / LLM LLM · RAG · AI Agent · Text2SQL · PII Detection · Knowledge Distillation

AI Engineering LangChain · LangGraph · Tool Calling · Reranker

Backend / Data Python · FastAPI · PostgreSQL · pgvector · Redis · ChromaDB

EDUCATION

울산대학교

2018.03 — 2023.02

IT융합 · 소프트웨어공학

Naver Boostcamp AI Tech 4기

2022.09 — 2023.02

추천 시스템 · 머신러닝 엔지니어링

CERTIFICATE

ADsP

2024.06