

AI Engineer

LLM · RAG · AI Agent · Backend

PROFILE

실서비스 환경에서 AI 시스템의 정확도, 성능, 보안 및 안정성 문제를 해결하는 AI Engineer입니다. LangChain 기반 AI Agent와 RAG 시스템을 설계하고, LLM 기반 PII Detection 및 Text2SQL 시스템을 개발해왔습니다.

EXPERIENCE

GoyoAI AI Engineer

2023.12 — Present

외부 LLM 활용을 위한 PII 보안 계층 및 경량 탐지 모델

- 외부 LLM 호출 전 사용자 입력과 문서의 개인정보 및 민감정보를 탐지하는 PII 보안 계층을 설계하고 실제 운영 환경에 적용
- 대용량 문서 입력 시 **Qwen3 8B Teacher** 의 높은 inference latency를 개선하기 위해 합성 데이터와 PII Entity Annotation을 생성하고, **KLUE RoBERTa-large Student** 에 Knowledge Distillation을 적용하여 경량 PII 탐지 모델을 프로토타입으로 구현
- Teacher와 Student의 PII 검출 결과를 비교하여 긴 문맥 및 PII가 없는 입력 등을 포함한 주요 테스트 시나리오에서 성능을 검증하고, 평균 latency를 8.35초에서 0.06초로 단축하여 약 130배의 응답 속도 개선

PII Detection Qwen3 8B KLUE RoBERTa-large Knowledge Distillation

자연어 기반 정형 데이터 질의 및 Text2SQL 시스템

- 기존 ChromaDB 기반 RAG의 유사도 검색 방식에서는 관련 데이터가 여러 건 존재하더라도 일부 Chunk만 검색되는 문제를 해결하기 위해, 자연어 질문을 SQL로 변환하여 PostgreSQL에서 직접 조회하는 Text2SQL 시스템을 설계하고 실제 운영 환경에 적용
- LLM의 SQL 생성을 보조하기 위해 pgvector에서 유사 질문-쿼리 예제 **64개를 검색한 뒤 BAAI/bge-reranker-v2-m3로 상위 5개 Few-shot 예제를 선별** 하고, 테이블 DDL·컬럼 설명·샘플 데이터 3행을 Schema Context로 제공하여 데이터베이스 구조를 기반으로 SQL을 생성하도록 구성
- 생성된 SQL을 PostgreSQL에서 실행하고, 실행 오류 발생 시 **DB 오류 메시지를 LLM에 전달하여 SQL을 수정하고 재실행** 하는 흐름을 구성했습니다. 조회 결과는 TSV 형태로 제공하고, 마지막 SQL을 재실행하여 전체 결과를 Interactive Table로 제공하며 CSV 및 Excel Export를 지원

Text2SQL LLM Tool Calling PostgreSQL pgvector bge-reranker-v2-m3

역할 기반 AI Agent 구조 설계 및 개발

- 역할에 따라 필요한 업무 기능과 참고 정보를 활용할 수 있도록 기존 RAG·Reranker와 다양한 업무 서비스를 Agent Tool로 연결하는 구조를 설계하고, 메일·일정·사내 공지·Notion·날씨·사내 투표 등의 기능을 연동
- Notion Tool을 직접 구현** 하여 키워드 기반 페이지 검색부터 상세 내용 조회, 데이터 가공 및 검색 결과 후처리까지 구성. 여러 검색 키워드에 대한 API 요청을 비동기로 처리하고, 기존 Reranker를 활용하여 검색 결과를 재정렬한 뒤 중복 문서를 제거하고 관련도 순으로 제공
- 기존 RAG와 Reranker를 Agent 구조에 적용하고, 외부 최신 정보가 필요한 질의에는 **Perplexity 기반 웹 검색** 을 활용할 수 있도록 구성하여 사내 문서 검색과 외부 웹 검색 및 업무 Tool을 Agent가 활용할 수 있는 정보 조회 구조를 설계

LangChain Tool Calling RAG Reranker Perplexity

TECHNICAL SKILLS

AI / LLM LLM · RAG · AI Agent · Text2SQL · PII Detection · Knowledge Distillation

AI Engineering LangChain · LangGraph · Tool Calling · Reranker

Backend / Data Python · FastAPI · PostgreSQL · pgvector · Redis · ChromaDB

EDUCATION

울산대학교

2018.03 — 2023.02

IT융합 · 소프트웨어공학

Naver Boostcamp AI Tech 4기

2022.09 — 2023.02

추천 시스템 · 머신러닝 엔지니어링

CERTIFICATE

ADsP

2024.06